

Министерство науки и высшего образования Российской Федерации  
Федеральное государственное автономное образовательное учреждение  
высшего образования  
«Уральский федеральный университет  
имени первого Президента России Б.Н. Ельцина»  
**Международный научно-методический центр трансфера компетенций  
цифровой экономики**

ДОПУСТИТЬ К ЗАЩИТЕ

\_\_\_\_\_  
(подпись) А.В.Созыкин  
(Ф.И.О.)

«\_\_\_\_\_» \_\_\_\_\_ 2020 г.

**ИТОГОВАЯ АТТЕСТАЦИОННАЯ РАБОТА**  
по программе профессиональной переподготовки  
«Искусственный интеллект и машинное обучение»

на тему: Анализ качества работы предварительно обученных нейронных сетей

---

Слушатели:



Созинов Андрей Викторович  
Плотников Алексей Михайлович

Группа:

Руководитель итоговой аттестационной  
работы:

Созыкин Андрей Владимирович

Екатеринбург  
2020

# СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1. ОБЗОР ТЕХНОЛОГИЙ АНАЛИЗА ИЗОБРАЖЕНИЙ С ПОМОЩЬЮ НЕЙРОННЫХ СЕТЕЙ .....	4
1.1. Обзор задачи анализа изображений .....	4
1.2. Обзор архитектур нейронных сетей .....	5
2. РАЗРАБОТКА СИСТЕМЫ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА .....	11
2.1. Постановка задачи машинного обучения .....	11
2.2. Описание набора данных.....	11
2.3. Подготовка набора данных.....	11
2.4. Описание архитектуры нейронных сетей .....	11
3. ВЫЧИСЛИТЕЛЬНЫЕ ЭКСПЕРИМЕНТЫ.....	13
3.1. Описание набора данных.....	13
3.2. Подготовка данных для распознавания .....	14
3.3. Анализ качества обучения.....	14
ЗАКЛЮЧЕНИЕ .....	19
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....	20

## ВВЕДЕНИЕ

Одним из аспектов использования глубоких нейронных сетей является, так называемое, компьютерное зрение, то есть задача распознавания изображений различных объектов. Данная задача подразумевает классификацию нейронной сетью объектов на изображениях. В настоящее время распознавание изображений нейронными сетями применяется во многих областях. Это и распознавание симптомов заболеваний в медицине, и чтение рукописного текста, и ориентирование автомобиля на дороге, и определение вида животных, насекомых, растений и т.д. Таким образом, распознавание изображений нейронными сетями не только не теряет своей актуальности, но наоборот приобретает всё большую популярность и входит в новые области общественной науки и практики.

Распознавание (классификация) изображений объектов выполняется как нейронными сетями, создаваемыми «с нуля» под конкретные группы объектов, так и предварительно обученными нейронными сетями, созданными сотрудниками компаний Microsoft, Google и других организаций – VGG, ResNet, DenseNet, Inception, Xception и др. Кроме того, существует значительный пласт исследований по оптимизации (дообучению) предварительно обученных нейронных сетей под конкретные задачи, наборы изображений. При этом оценивается качество работы предварительно обученных нейронных сетей, взятых за основу и качество работы модифицированных (дообученных) нейронных сетей.

Цель работы. Определить предварительно обученную нейронную сеть с максимальным качеством распознавания изображений.

Задачи.

- проанализировать набор изображений;
- подготовить набор данных для распознавания;
- применить предварительно обученные модели для распознавания (классификации) 20 изображений;
- оценить качество распознавания изображений;
- выявить нераспознанные изображения.

# 1. ОБЗОР ТЕХНОЛОГИЙ АНАЛИЗА ИЗОБРАЖЕНИЙ С ПОМОЩЬЮ НЕЙРОННЫХ СЕТЕЙ

## 1.1. Обзор задачи анализа изображений

В настоящее время для решения задач обработки изображений с применением информационных технологий всё шире используются нейронные сети, которые зачастую превосходят классические методы, такие как метод главных компонент, метод ближайшего соседа, линейный дискриминантный анализ и другие.

По своей сути нейронная сеть это программа, которая в качестве входных данных получает изображение, производит с ним определенные манипуляции, в ходе которых выделяет наиболее значащие, типичные черты (признаки) объекта на изображении, по которым, в итоге, относит изображение к тому или иному классу. В структуре нейронной сети выделяют разного рода слои, выполняющие различные функции обработки изображения – сверточные (convolution layers), слои подвыборки (pooling layers), полносвязные и другие. Каждый слой, состоит из элементов – искусственных нейронов, названных так по аналогии с нейронами головного мозга (рисунок 1).




Рисунок 1 – Нейроны головного мозга (а) и нейроны искусственной сети (б) [1]

Нейронная сеть в процессе обучения самостоятельно определяет какие признаки в исходном изображении важны, а какие нет. Поэтому может быть подобрано такое сочетание признаков, до которого человек никогда бы не догадался. Архитектура нейронной сети включает в себя входной слой, выходной слой и скрытые между ними слои, где выполняются вычисления. Структура нейронных

сетей, используемых для классификации изображений является однонаправленной, то есть без обратных связей, и многослойной. В процессе обучения нейронной сети обычно используется метод обратного распространения ошибки, а функция активации выбирается исследователем.

При решении задач обработки изображений наиболее часто используются сверточные нейронные сети, содержащие три основных типа скрытых слоев – слои свертки, слои подвыборки и полносвязные слои [2]. Слои свертки осуществляют фундаментальную обработку изображений, заключающуюся в фильтрации входного изображения с помощью разнообразных фильтров или ядер. Слои подвыборки уменьшают размерность входной матрицы в два и более раз, при этом увеличивается абстракция извлекаемых признаков. Полносвязные слои используются для классификации входного изображения в соответствии с заранее определенными классами.

## **1.2. Обзор архитектур нейронных сетей**

В последние годы технологии компьютерного зрения получили широкое распространение – они применяются для распознавания лиц, различных объектов, медицинского анализа, навигации автомобилей и так далее. Ежегодные соревнования по распознаванию изображений ImageNet Large Scale Visual Classification Challenge (ILSVCC) с 2012 года выигрывают участники, использующие сверточные нейронные сети [3].

Наиболее часто применяемыми для анализа изображений сверточными нейронными сетями являются VGG, ResNet, DenseNet, Inception, Xception и другие.

Архитектура нейронной сети Visual Geometry Group (VGG) имеет четыре варианта – VGG-11, VGG-13, VGG-16 и VGG-19, различающихся количеством уровней. Сеть VGG-16 была разработана сотрудниками Оксфордского университета K. Simonyan, A. Zisserman [4], в 2014 году заняла первое место на конкурсе ImageNet. Особенностью архитектуры данной сети является сверточное ядро размером 3x3 пикселя. Часть сети, выделяющая признаки изображения состоит из чередующихся сверточных блоков, где два блока имеют вид «сверточный слой - сверточный слой - слой подвыборки» и три блока – «свертка – свертка – свертка

- слой подвыборки». На слое подвыборки выполняется операция максимального объединения с ядром свертки  $2 \times 2$ . Классификатор состоит из трех полносвязных слоев. Сеть VGG-16 получает на вход изображения размером  $224 \times 224$  пикселя в трех цветовых каналах, а на выходе получают вероятности принадлежности объекта к определенному классу (Рисунок 2).




Рисунок 2 – Архитектура сверточной нейронной сети VGG16 [5]

Модель нейронной сети ResNet (Residential Network) разработана корпорацией Microsoft, является победителем конкурса ImageNet 2015 года. В сети ResNet используется двухуровневый метод обхода, а также слои фильтрации (bottleneck layers), которые уменьшают количество объектов в каждом слое, используя свертку  $1 \times 1$  с меньшим выходом объектов, и затем свертки  $3 \times 3$ . Выходной слой сети – это слой подвыборки с функцией Softmax (рисунок 3).

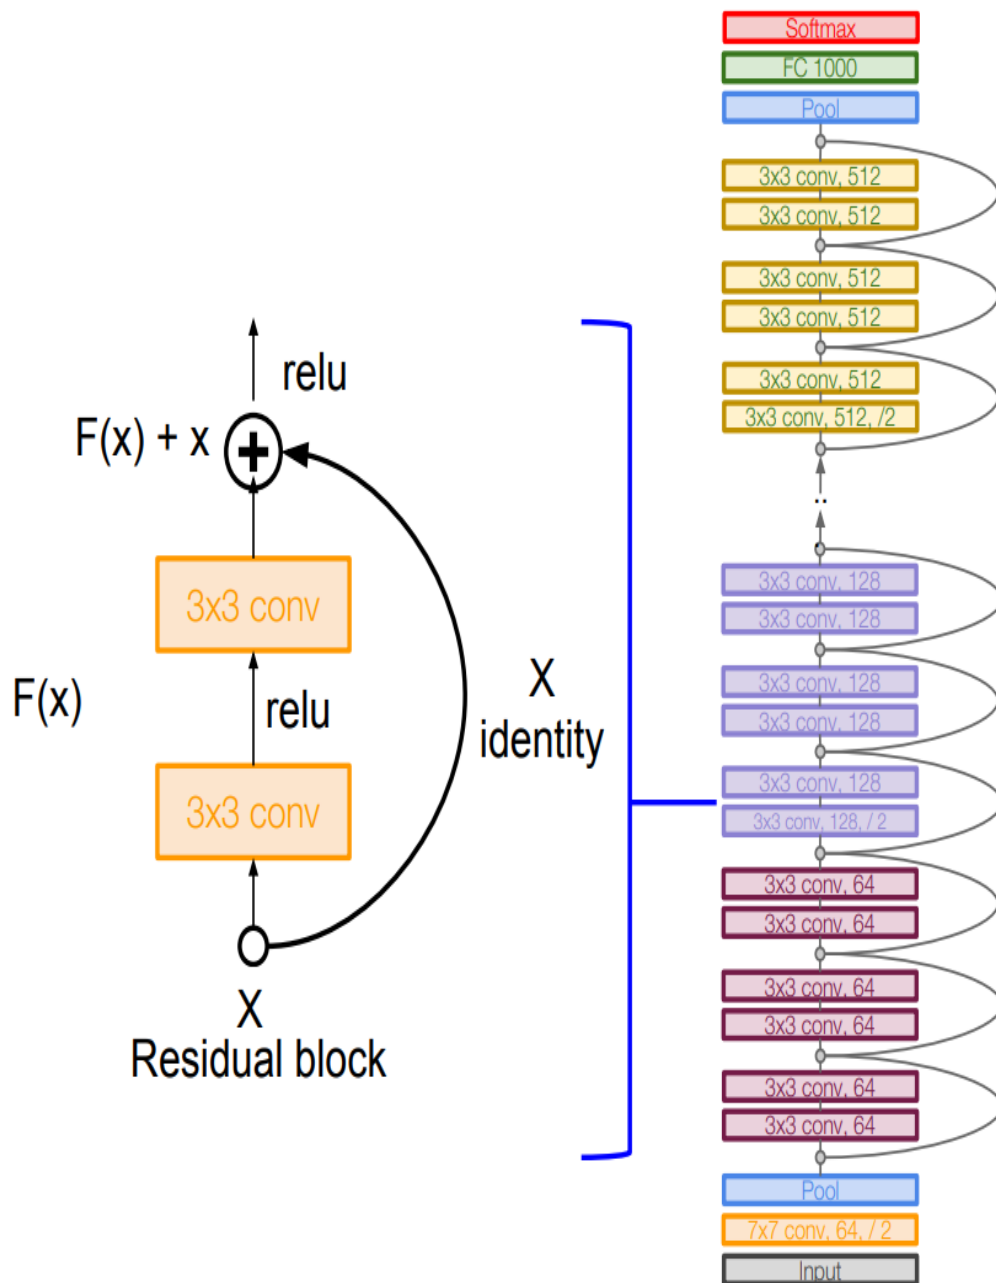


Рисунок 3 – Архитектура нейронной сети ResNet [6]

Результатом развития нейронной сети ResNet является сверточная нейронная сеть DenseNet (Densely Connected Convolutional Networks) [7]. В сети DenseNet соединения имеют все возможные комбинации в каждом блоке, то есть каждый слой соединен со всеми другими слоями в режиме прямой связи. В ней облегчена проблема, связанная с очень малыми значениями градиента, улучшено распространение признаков, выполняется повторное использование признаков и существенно сокращено количество настраиваемых параметров (рисунок 4).






Рисунок 4 – Архитектура нейронной сети DenseNet [8]

Для распознавания изображений компанией Google разработана сверточная нейронная сеть Inception-V3. В этой сети задействован метод пакетной нормализации, в котором выполняется вычисление среднего и стандартного отклонения для всех карт распределения признаков в выходном слое и их нормализация с использованием этих значений. Последний слой сети Inception – слой подвыборки с функцией Softmax (рисунок 5).




Рисунок 5 – Архитектура нейронной сети Inception-V3 [8]



Для обучения сети Inception необходимо привести входные изображения к размеру 299x299 пикселей. Данная архитектура, по мнению своих создателей, является перспективной и может использоваться для решения широкого круга задач.

Модель Xception является модификацией сети Inception. Она была реализована Ф. Шоле в открытой библиотеке Keras [9]. Архитектура сети аналогична ResNet-34, но модель и код проще, чем в Inception. Отличительной особенностью является отдельный сверточный слой (SeparableConv), который является изменяемой и отделяемой сверткой, расположенной в верхней части сетевой архитектуры. В сети имеются остаточные соединения, взятые из сети ResNet. В результате их использования точность классификации объектов была значительно повышена (рисунок 6).

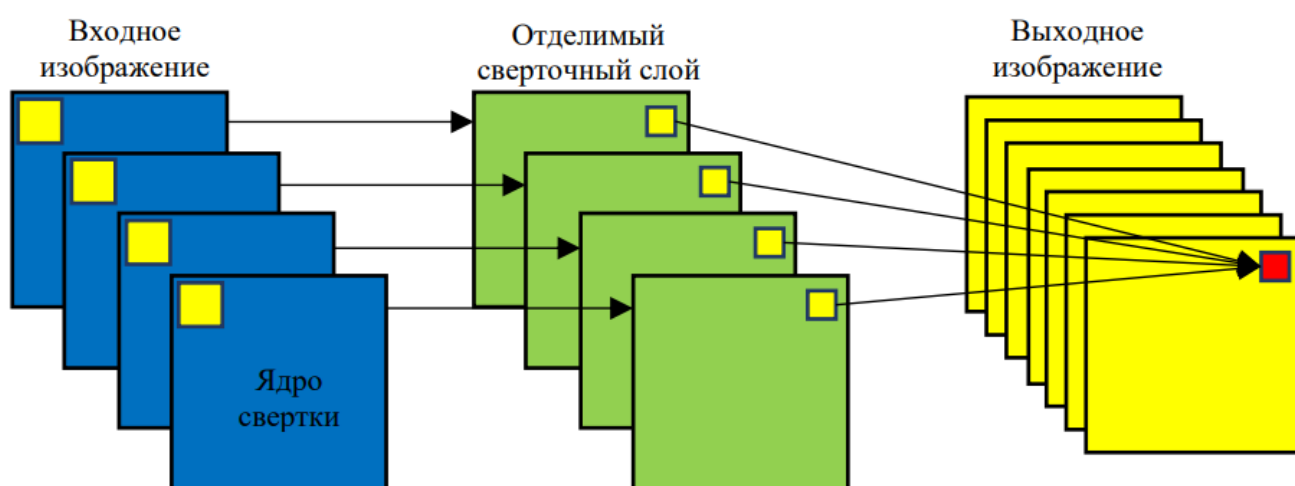


Рисунок 6 – Архитектура нейронной сети Xception [8]

В целом, сверточные нейронные сети во многих задачах дают значительно более высокую точность распознавания объектов на изображениях по сравнению с другими методами машинного обучения. По сравнению с полносвязной нейронной сетью у сверточной сети гораздо меньше обучаемых весов. Сверточные сети обладают относительной устойчивостью к повороту и сдвигу распознаваемого изображения.

В то же время, недостатком сверточных нейронных сетей является значительное количество настраиваемых исследователем параметров. При этом часто неясно, какие оптимальные значения параметров нужно выбрать для конкретной

задачи. К таким параметрам относятся – количество слоев, размерность ядра свертки, количество ядер, необходимость и количество слоев подвыборки, степень уменьшения ими размерности, функция по уменьшению размерности (выбор максимума, среднего и другие), функция активации нейронов, наличие и параметры полносвязной нейронной сети на выходе сверточной. Все перечисленные параметры существенно влияют на результат, но подбираются исследователем эмпирически.

## **2. РАЗРАБОТКА СИСТЕМЫ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА**

### **2.1. Постановка задачи машинного обучения**

Задачей машинного обучения для анализа качества работы предварительно обученных нейронных сетей является необходимость проанализировать качество работы сверточных сетей VGG-16, VGG-19, ResNet50, DenseNet201, InceptionV3, Xception.

### **2.2. Описание набора данных**

В работе проводится сравнение предварительно обученных нейронных сетей. Выбранные нейронные сети обучены на наборе изображений ImageNet. Это база данных изображений, организованная в соответствии с иерархией базы данных WordNet, в которой каждый узел иллюстрирован сотнями и тысячами изображений. В настоящее время в среднем на каждый узел приходится более 500 изображений. Ежегодно проводятся конкурсы по лучшему распознаванию и классификации изображений ImageNet. В базе данных содержатся миллионы URL с изображениями, прошедшими ручную аннотацию. Сами изображения не принадлежат проекту. В 2017 году в ImageNet были представлены более 14 миллионов изображений, разбитых на 21 841 категорию.

### **2.3. Подготовка набора данных**

Для обучения сверточных нейронных сетей исходный пул изображений делится на три части – обучающая, проверочная и тестовая. С 2010 года в ежегодном соревновании ImageNet Large-Scale Visual Recognition Challenge используется выборка из ImageNet размером 1000 изображений в каждой из 1000 категорий. Таким образом, обучающий набор состоит из 1,2 миллионов изображений, проверочный – из 50 тыс. изображений и тестовый – из 150 тыс. изображений.

Поскольку в ImageNet входят изображения разных размеров, их необходимо привести к единому размеру 256x256.

### **2.4. Описание архитектуры нейронных сетей**

Для анализа качества работы предварительно обученных нейронных сетей были выбраны шесть моделей сверточных нейронных сетей – VGG-16, VGG-19,

ResNet50, DenseNet201, InceptionV3, Xception. Архитектура выбранных сетей разобрана в первой главе.

VGG16 имеет 138357544 параметра, ее глубина 23 слоя. Это глубокая нейронная сверточная сеть, имеющая последовательное применение слоев и из-за этого все же ограниченная по глубине. Имеет две версии – 16 и 19 слоев.

ResNet50 имеет 25636712 параметров. Использует непоследовательные преобразования, периодически объединяя (суммированием) выход текущего слоя с выходом слоя, который был обработан на несколько шагов ранее. Тем самым борется с потерей информации при большой глубине нейронной сети.

DenseNet201 содержит 20242984 параметра, глубина сети 201 слой. Состоит из «плотных» блоков. Каждый блок принимает на вход все предыдущие карты признаков. При этом объединение карт, в отличие от ResNet, где происходит суммирование карт признаков, происходит конкатенированием.

InceptionV3 - 23851784 параметра, глубина – 159 слоев. Основана на блоках с древовидной архитектурой. Этот блок параллельно применяет к слою несколько операций, а затем агрегирует всю информацию снова в один слой. Также при большом увеличении слоев архитектура может иметь несколько выходных классификаторов для борьбы с затуханием градиентов.

Xception содержит 22910480 параметров, глубина 126 слоев. Отличается тем, что отдельно выполняет обработку и преобразование канальной информации, а отдельно пространственной. Канальная информация извлекается свертками  $1 \times 1$ , а пространственная выделяется сверткой  $3 \times 3$ , но к каждому каналу по отдельности.

### 3. ВЫЧИСЛИТЕЛЬНЫЕ ЭКСПЕРИМЕНТЫ

#### 3.1. Описание набора данных

Оценка качества работы предварительно обученных нейронных сетей проводилась на собственном наборе данных, состоящем из 20 цветных изображений различных объектов. На 17 изображениях присутствуют по одному объекту на однородном фоне, на трех изображениях объекты расположены на разнородном фоне. Формат анализируемых изображений – jpeg, размер – 300x300 пикселей (рисунок 7).

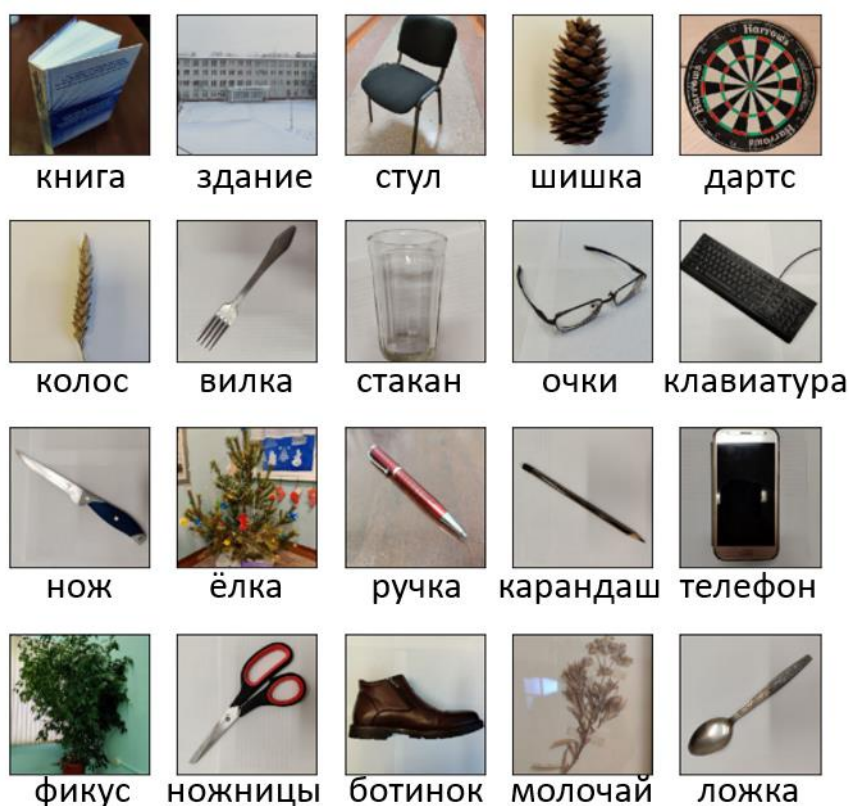


Рисунок 7 – Набор изображений, используемых для оценки качества работы предварительно обученных нейронных сетей

В набор изображений вошли разнообразные объекты, как естественного (биологического), так и искусственного происхождения. Объекты характеризуются разными размерами, положением на изображении, что должно затруднять распознавание объектов нейронной сетью. Набор данных доступен по ссылке <https://www.dropbox.com/s/whi73z8w0q9on9w/images.zip?dl=0>.

### 3.2. Подготовка данных для распознавания

Цветные изображения объектов из собственного набора данных для распознавания предварительно обученными нейронными сетями VGG16, VGG19, ResNet50, DenseNet201 были приведены к размеру 224x224 пикселя. Изображения для распознавания нейронными сетями InceptionV3 и Xception были приведены к размеру 299x299 пикселей.

После изменения размеров каждое изображение перед подачей в предварительно обученную нейронную сеть переводилось в массив.

### 3.3. Анализ качества обучения

Результаты распознавания набора изображений предварительно обученными нейронными сетями представлены в таблице 1. Анализ качества работы нейронных сетей показал, что безошибочно все нейронные сети с высокой долей вероятности распознали только один объект из двадцати – шариковую ручку. Пять из шести рассматриваемых нейронных сетей правильно распознали мобильный (сотовый) телефон. Нейронная сеть VGG16 классифицировала мобильный телефон как плеер iPod с вероятностью 50,66%, что с некоторой натяжкой можно засчитать за верный ответ. И третьим правильно распознанным объектом оказалась компьютерная клавиатура. Правильный результат показали сети VGG16, ResNet50 и Inception\_v3. Остальные три сети классифицировали клавиатуру как мышь, вероятно компьютерную.

Правильным распознаванием можно считать определение нейронной сетью общей группы классов, к которой относится объект. Следующие семь объектов нейронные сети распознали верно, но не совсем точно – стул, стакан, здание, очки, нож, обувь, чайная ложка. Например, пять нейронных сетей указали, что на изображении находится складной стул, а сеть DenseNet201 определила, что это парикмахерское кресло. Хотя на самом деле, на изображении обычный офисный стул, не складной. То есть, неточность в классификации присутствует, но можно засчитать ответы как верные, так как все они относятся к группе мебели, на которой можно сидеть.

Таблица 1 - Результаты распознавания изображений предварительно обученными нейронными сетями

Изображение	VGG16		VGG19		ResNet50		DenseNet201		Inception_v3		Xception	
	preds	%	preds	%	preds	%	preds	%	preds	%	preds	%
1	2	3	4	5	6	7	8	9	10	11	12	13
Книга	картонная коробка	34.80	картонная коробка	69.82	картонная коробка	40.58	пакет	38.55	пакет	16.72	картонная коробка	25.17
Здание	снегоочиститель	9.14	тюрьма	21.97	дворец	52.01	трамвай	12.39	<b>дворец</b>	<b>11.70</b>	<b>тюрьма</b>	<b>17.78</b>
Стул	складной стул	98.17	складной стул	99.12	складной стул	38.50	<b>парикмахерское кресло</b>	<b>47.91</b>	<b>складной стул</b>	<b>26.45</b>	<b>складной стул</b>	<b>42.38</b>
Шишка	ананас	34.93	конский каштан	47.77	катушка	24.72	перо	29.92	трилобит	18.44	морской огурец	19.02
Доска дартс	магнитный компас	87.19	поднос	24.87	магнитный компас	44.97	магнитный компас	88.55	магнитный компас	94.70	магнитный компас	34.69
Колос пшеницы	перо	91.45	перо	53.53	многоножка	86.75	перо	94.91	аксолотль	17.77	перо	93.36
Вилка	половник	38.04	лопатка	72.66	канцелярский нож	39.54	лопатка	58.08	лопатка	73.29	отвертка	27.27
Стакан	бокал	30.65	мерный стакан	47.94	пивной бокал	22.23	<b>мерный стакан</b>	<b>26.65</b>	<b>мерный стакан</b>	<b>15.40</b>	<b>бокал</b>	<b>20.96</b>
Очки	солнечные очки	10.43	намордник	21.04	галстук болю	21.78	<b>солнечные очки</b>	<b>33.75</b>	<b>солнечные очки</b>	<b>14.70</b>	стетоскоп	11.54
Клавиатура	клавиатура	45.13	мышь	26.45	клавиату-ра	49.88	мышь	41.26	<b>клавиатура</b>	<b>60.20</b>	мышь	44.52
Нож	тесак	33.13	канцелярский нож	71.95	тесак	48.42	<b>тесак</b>	<b>63.41</b>	<b>тесак</b>	<b>39.71</b>	ножны	34.06
Елка новогодняя	алтарь	91.49	алтарь	75.31	алтарь	32.56	горшок	46.05	горшок	44.12	горшок	47.41
Ручка	ручка	94.01	ручка	79.38	ручка	78.13	<b>ручка</b>	<b>78.31</b>	<b>ручка</b>	<b>87.89</b>	<b>ручка</b>	<b>87.38</b>
Карандаш	гвоздь	27.94	гвоздь	34.08	гвоздь	67.65	гвоздь	78.94	ручка	42.25	ручка	76.15
Телефон	iPod	50.66	сотовый телефон	54.26	сотовый телефон	87.77	<b>сотовый телефон</b>	<b>95.73</b>	<b>сотовый телефон</b>	<b>89.02</b>	<b>сотовый телефон</b>	<b>99.75</b>



Окончание таблицы 1

1	2	3	4	5	6	7	8	9	10	11	12	13
Фикус	горшок	37.60	горшок	56.19	горшок	97.83	горшок	78.76	горшок	90.62	горшок	80.53
Ножницы	консервный нож	22.50	консервный нож	33.93	консервный нож	38.81	канцелярский нож	81.54	канцелярский нож	8.97	консервный нож	51.83
Ботинок	ковбойский сапог	66.04	лоферы	35.79	ковбойский сапог	61.00	<b>лоферы</b>	<b>59.13</b>	<b>лоферы</b>	<b>35.29</b>	<b>лоферы</b>	<b>61.26</b>
Молочай	ваза	10.28	ваза	8.62	ваза	53.97	ваза	52.31	ваза	54.98	ваза	35.47
Ложка	половник	88.62	половник	92.62	половник	72.78	<b>половник</b>	<b>99.32</b>	<b>половник</b>	<b>35.78</b>	<b>половник</b>	<b>65.96</b>
ИТОГО:	45%		40%		45%		40%		50%		35%	

Подобная ситуация отмечена и с некоторыми другими изображениями. При определении качества работы нейронных сетей было принято решение засчитывать такие неточные распознавания как верные. И только если предполагаемый нейронной сетью класс совершенно не относится к размещенному на изображении объекту, такой ответ считался неверным. Например, при распознавании изображения с четырехэтажным зданием, сети VGG19 и Xception выдали результат «тюрьма», сети ResNet50 и Inception\_v3 отнесли изображение к классу «дворец». Поскольку все эти объекты являются зданиями, эти ответы были засчитаны как верные. В то же время сеть VGG16 распознала объект как «снегоочиститель», а сеть DenseNet201 как «трамвай». Данные ответы были засчитаны как неверные.

Десять изображений из представленного набора не распознала ни одна из анализируемых нейронных сетей. На пяти из этих изображениях находятся объекты биологического происхождения – еловая шишка, колос пшеницы, комнатное растение (фикус), новогодняя елка (сосна), засушенный молочай. То есть, ни один объект биологического происхождения не был верно классифицирован ни одной из шести нейронных сетей. Вероятно, это указывает на то, что для повышения качества распознавания биологических объектов предварительно обученные нейронные сети нуждаются в дообучении на специальных наборах биологических изображений. Данное направление машинного обучения представляет высокий интерес для специалистов АПК, поскольку имеется потребность в системах, способных быстро распознавать виды культурных и сорных растений, сельскохозяйственных вредителей, внешние признаки заболеваний растений, для своевременного принятия решений по защите растений от вредителей, заболеваний и сорняков.

Учитывая вышесказанное, было подсчитано количество верных и неверных результатов классификации 20-ти изображений рассматриваемыми предварительно обученными нейронными сетями. Верные результаты нейронные сети показали в 35-50 % случаев. Минимальным качеством работы по предложенному набору данных характеризуется нейронная сеть Xception. Максимальный результат (50%) показала нейронная сеть Inception-v3.

Таким образом, проведенный анализ качества распознавания изображений на собственном наборе данных предварительно обученными нейронными сетями

показал, что до 50% изображений могут быть распознаны без дообучения. Однако, задача распознавания специфических изображений требует дополнительной настройки нейронных сетей на отдельных наборах данных.

## ЗАКЛЮЧЕНИЕ

Краткое описание полученных результатов:

Цель работы: определить предварительно обученную нейронную сеть с максимальным качеством распознавания изображений.

Постановка задачи машинного обучения: задача классификации, 20 собственных изображений, на каждом изображении только один объект.

Использованные нейронные сети: VGG16, VGG19, ResNet50, DenseNet201, InceptionV3, Xception.

Доля правильных ответов нейронных сетей: 35-50%

Максимальное качество распознавания изображений (50 %) показала предварительно обученная нейронная сеть InceptionV3.

Ссылка на ноутбук с полным кодом решения – <https://colab.research.google.com/drive/1edrCx3BiBBzOQ7ef1pD2t4STWsDGYJA7?usp=sharing>

Планируемые дальнейшие шаги.

Провести анализ качества работы по распознаванию изображении другими предварительно обученными сетями: ResNet152V2, NASNetLarge и т.п.

Протестировать работу нейронных сетей на других изображениях.

Применить предварительно обученные нейронные сети на наборах изображений культурных и сорных растений, сельскохозяйственных вредителей, внешних проявлениях заболеваний и повреждений культурных растений.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Goodfellow, I. Deep Learning [Электронный ресурс] / I. Goodfellow, Y. Bengio, A. Courville // MIT press. – Режим доступа: <https://mitpress.mit.edu/books/deep-learning> (дата обращения: 04.01.2021)
2. Kumar, N. Understanding convolution neural networks [Электронный ресурс] / N. Kumar // The ELI5. – Режим доступа: <https://towardsdatascience.com/understanding-convolution-neural-networks-the-eli5-way-785330cd1fb7> (дата обращения: 06.01.2021)
3. ImageNet Large Scale Visual Recognition Competition 2014 (ILSVRC2014) [Электронный ресурс]. – Режим доступа: <http://www.image-net.org/challenges/LSVRC/2014/results> (дата обращения: 28.12.2020).
4. Simonyan, K. Very deep convolutional networks for large-scale image recognition / K. Simonyan, A. Zisserman // Computer Science: Computer vision and pattern recognition. – 10.04.2015.
5. Neurohive VGG16 — сверточная сеть для выделения признаков изображений <https://neurohive.io/ru/vidy-nejrosetej/vgg16-model/>
6. Стэнфордский курс: лекция 9. Архитектуры CNN <https://www.reg.ru/blog/stehnfordskij-kurs-lekciya-9-arhitektury-cnn/>
7. Huang, G. Densely connected convolutional networks / G. Huang, Z. Liu, L. van der Maaten, K.Q. Weinberger // Computer Science: Computer vision and pattern recognition. – 28.06.2018.
8. Сафонова А.Н. Методы машинного обучения при обработке изображений сверхвысокого пространственного разрешения на примере задач классификации растительности // Диссертация на соискание ученой степени кандидата технических наук. – Красноярск: ФГАОУ ВО «Сибирский федеральный университет», 2019. – 104 с.
9. Chollet, F. Xception: deep learning with depthwise separable convolutions / F. Chollet // Computer Science: Computer vision and pattern recognition. – 04.04.2017.